




Análise Exploratória de Dados com Python e Pandas

Transformando dados brutos em
decisões operacionais ágeis para
gestão de estoques.



O Limite das Planilhas Convencionais

O que você faz quando a sua planilha trava com 1 milhão de linhas de movimentação de carga?

Objetivos de Aprendizagem

O que dominaremos hoje

Nesta aula do Bloco 05, você desenvolverá:

Scripts Python: carregar e inspecionar dados.


Pandas: filtrar, tratar e agrupar registros.

Relatórios: gerar estatísticas automatizadas.



Lembre-se


Computação científica acelera fluxos e reduz custos via detecção de anomalias.



Vocabulário Essencial da Aula



Python:
Linguagem líder
em ciência de
dados e
automação
corporativa.



Pandas: Biblioteca
Python para
manipulação ágil
de dados
tabulares.

CÓDIGO	PRODUTO	ESTOQUE ATUAL	ESTOQUE MÍNIMO	STATUS	LOCAL
P001	Parafuso M5	124	50	OK	A1
P002	Parafuso M6	287	100	OK	A1
P003	Arruela M5	340	150	OK	A2
P004	Identificador de Níveis	085	50	OK	B1
P005	Fita Isolante	052	30	OK	B2
P006	Capacitor Eletrolítico	119	50	OK	C1
P007	Linha de Soldagem	036	20	OK	C2
P008	Lâmpada LED	078	40	OK	D1

DataFrame:
Estrutura
bidimensional
mutável com
colunas e eixos
rotulados.



**Análise
Exploratória:**
Método para
resumir dados via
estatística e
gráficos.

Recapitulação: O Papel do SQL



Da Consulta à Programação

No Bloco 04, usamos **SQL** para consultar bancos relacionais via `,` `,` e `.`

Agora, levamos dados ao Python. Enquanto o SQL extrai dados do servidor, o Python permite limpezas, automação de rotinas e modelagem estatística local.



Ponto-chave

O pipeline corporativo extrai tabelas via SQL e executa a engenharia analítica no Pandas.

Verificação de Aprendizagem: SQL e Dados



Pergunta 1:

Qual comando SQL é utilizado para combinar linhas de duas tabelas com base em uma coluna comum?

Pergunta 2:

Qual cláusula filtra registros agrupados após a execução de uma agregação com GROUP BY?

Pergunta 3:

Em arquitetura de dados, qual é a principal vantagem de combinar consultas SQL com scripts Python?

Verificação de Aprendizagem: SQL e Dados

Resposta 1:

JOIN (ou INNER JOIN)

Resposta 2:

HAVING

Resposta 3:

O SQL extrai dados filtrados do servidor e o Python executa modelagens estatísticas e transformações complexas.

Fundamentos: Variáveis e Tipos no Python

SINTAXE BÁSICA

Estruturação e Tipagem Dinâmica

No Python, variáveis não exigem declaração explícita de tipo. A linguagem infere automaticamente se o valor é inteiro (), ponto flutuante (), texto () ou booleano ().



Exemplo

A clareza dos nomes de variáveis evita falhas de rastreabilidade em auditorias operacionais.



Controle de Fluxo e Decisões Lógicas

Condicionais (if / elif / else)

Permitem aplicar regras de negócio no fluxo de suprimentos, como disparar ordens automáticas de compra quando o saldo atinge o ponto de reposição operacional.



Ponto-chave

Estruturas condicionais implementam políticas de estoque com exatidão matemática.

Loops de Iteração (for / while)

Percorrem listas de itens, lotes de notas fiscais ou coleções de registros para calcular custos acumulados ou validar cadastros repetitivos de fornecedores.



Exemplo


Loops padronizam auditorias rotineiras de milhares de linhas sem intervenção manual.

Modularização com Funções Customizadas

BOAS PRÁTICAS

Reutilização de Código

Funções encapsulam cálculos recorrentes, como **Estoque de Segurança** ou Giro de Itens. Evita copiar fórmulas, reduz erros e facilita a manutenção de regras logísticas.



Lembre-se

Entradas claras e 'return' garantem confiabilidade ao pipeline.

Checagem: Funções e Modularização

Qual é a palavra-chave reservada utilizada para definir uma função customizada em Python?

1.

create

2.

function

3.

module

4.

def

Checagem: Funções e Modularização



Qual é a palavra-chave reservada utilizada para definir uma função customizada em Python?

1.

create

2.

function

3.

module

4.

def



NumPy: Alta Performance e Vetorização

COMPUTAÇÃO MATRICIAL

Além das Listas Convencionais

O **NumPy** usa : estrutura homogênea em blocos de memória contíguos, processada via código C.

A **vetorização** aplica operações aritméticas sem laços lentos, processando milhões de registros de estoque instantaneamente.



Curiosidade

Pandas usa o NumPy como base para garantir alta velocidade em tabelas.



Comparando Listas Nativas e Arrays NumPy

Listas Padrão do Python

- Aceitam tipos heterogêneos misturados na mesma coleção.
- Armazenam ponteiros dispersos na memória RAM.
- Exigem laços manuais para operações elemento a elemento.



Atenção

Ineficientes para operações em larga escala na gestão de estoques corporativos.

Arrays do NumPy (ndarray)

- Exigem tipo de dado estritamente uniforme e compacto.
- Alocação contígua e otimizada na memória do computador.
- Operações vetorizadas ultravelozes com aceleração de hardware.



Ponto-chave

Garante até cinquenta vezes mais rapidez em cálculos matriciais de inventário.

Anatomia do Pandas: Series e DataFrames


ESTRUTURAS DO PANDAS

Os Pilares do Pacote

O Pandas usa dois objetos centrais:

Series: Matriz unidimensional rotulada para qualquer tipo de dado (uma coluna).

DataFrame: Tabela bidimensional com linhas, colunas e índices flexíveis.



Lembre-se

DataFrames são dicionários de Series com índices compartilhados.

Indexação e Fatiamento: loc versus iloc

Seleção por Rótulo com .loc

Utiliza nomes de colunas e índices explícitos para recuperar observações. Permite fatias baseadas em texto ou máscaras lógicas, como buscar .



Exemplo

Ideal para regras de negócio baseadas em códigos de produto.

Seleção por Posição com .iloc

Realiza o fatiamento pela coordenada inteira de linhas e colunas, iniciando no zero. Útil para isolar as primeiras dez ocorrências ou descartar a última coluna com .



Ponto-chave

Perfeito para processamento agnóstico a cabeçalhos.

Fixação de Conceito: Indexação no Pandas

O método `.iloc` aceita nomes textuais de colunas para filtrar subconjuntos de um DataFrame.



VERDAD
~~EIRO~~



FALSO



Prepare-se para explicar o seu raciocínio.

Fixação de Conceito: Indexação no Pandas

O método `.iloc` aceita nomes textuais de colunas para filtrar subconjuntos de um DataFrame.



VERDAD
EIRO



FALSO 



Por que é isso?

O método `.iloc` opera exclusivamente com posições inteiras numéricas, enquanto a busca por nomes de rótulos deve ser feita com `.loc`.

Ingestão e Exportação de Volumes Reais

PIPELINE DE DADOS

Conexão com Fontes Corporativas

O Pandas faz a ponte direta com repositórios de dados operacionais sem necessidade de conversão prévia manual:



Lembre-se

Definir o separador e a codificação correta na carga evita caracteres corrompidos nas descrições de itens.



Inspeção Preliminar de Integridade

Radiografia dos Primeiros Registros


Ao ler um arquivo de materiais, o primeiro passo analítico é avaliar a estrutura dos dados com comandos rápidos e não invasivos.

O método exibe as primeiras linhas, inspeciona o encerramento do arquivo e retorna a tupla exata de linhas e colunas carregadas.




Ponto-chave

Verificar as primeiras linhas confirma se os cabeçalhos foram alinhados corretamente pelo interpretador.




Exploração Prática em Vídeo

Pandas permite investigar suprimentos, corrigir erros e auditar movimentações fiscais.



Diagnóstico do Dataset: info() e Tipos



DIAGNÓSTICO TÉCNICO

Auditoria com info()

resume a saúde da tabela:

- Total de entradas e índice.
- Contagem de valores não nulos.
- Tipos de dados (int, float, object).
- Uso de memória RAM.



Atenção

Números como 'object' indicam sujeira (símbolos ou vírgulas).

Síntese Estatística com describe()

ESTATÍSTICA DESCRITIVA

Métricas Automáticas

gera parâmetros para colunas numéricas:

: Itens; : Média

: Desvio Padrão; /: Extremos

, , : Quartis



Ponto-chave

Média vs mediana revela lotes atípicos ou erros.



Métrica	 Preço Unitário	 Quantidade em Estoque
count	120	120
mean	42,75	68,30
std	15,82	41,27
min	5,90	0
25%	28,50	32,00
50%	39,90	61,00
75%	53,75	94,00
max	129,90	230,00

Tratamento de Dados Faltantes (NaN)



QUALIDADE DO DADO

Estratégias para Valores Nulos

Dados incompletos distorcem indicadores.

Ferramentas Pandas:

- : mapeia nulos por coluna.
- : remove registros inviáveis.
- : preenche lacunas com mediana histórica.



Atenção

Não exclua linhas sem validar impacto da perda de histórico no inventário.

Remoção de Duplicidades e Inconsistências

HIGIENIZAÇÃO OPERACIONAL

Integridade do Inventário Físico

Falhas de integração ou reenvios de notas geram duplicidades em relatórios de compras.

Com detectamos repetições. O método retém o registro original, saneando os livros contábeis.



Lembre-se

Eliminar duplicatas antes do fechamento mensal evita compras desnecessárias e custos extras.



Validação Prática: Limpeza de Dados

Para preencher valores nulos com a mediana usamos o método _____, enquanto para remover registros repetidos de inventário aplicamos _____.

Banco de palavras 

drop_duplicates

dropna

filter

replace

fillna

merge

Validação Prática: Limpeza de Dados



Para preencher valores nulos com a mediana usamos o método **fillna**, enquanto para remover registros repetidos de inventário aplicamos **drop_duplicates**.

Banco de palavras 🏛️

drop_duplicates

dropna

filter

replace

fillna

merge

Agregações e Segmentações com groupby()

O Padrão Split-Apply-Combine

Como no SQL, o Pandas consolida dados com sintaxe elegante e expressiva.

Agrupamento Simples

Divide o DataFrame por categoria, soma o custo e entrega o resultado consolidado em segundos.



Exemplo

Ideal para identificar famílias de produtos que absorvem mais capital.

Múltiplas Agregações

Aplica regras por filial, revelando médias de saldo e dispersões de preços por unidade.



Ponto-chave

Audita discrepâncias de valor entre centros de distribuição.

Junções e Fusão de Bases: merge e concat

INTEGRAÇÃO TABULAR

Cruzamento de Dados

Suprimentos, compras e almoxarifados usam tabelas distintas que exigem unificação:

- Junção relacional estilo SQL.
- Empilha tabelas mensais de vendas em base histórica única.



Lembre-se

Merge conecta entidades via chaves; concat une horizontes temporais.



Sequência do Pipeline de Tratamento

Ordene as etapas corretas para transformar dados brutos de notas fiscais em um relatório consolidado:

Importar os arquivos CSV brutos com tratamento de codificação e separadores.

Diagnosticar tipos de dados e identificar registros nulos ou duplicados com `info()` e `isna()`.

Executar agrupamentos com `groupby()` e exportar indicadores sumarizados para Excel.

Higienizar a base preenchendo nulos válidos e eliminando duplicidades operacionais.

Sequência do Pipeline de Tratamento




Ordene as etapas corretas para transformar dados brutos de notas fiscais em um relatório consolidado:

1
Importar os arquivos CSV brutos com tratamento de codificação e separadores.

2
Diagnosticar tipos de dados e identificar registros nulos ou duplicados com `info()` e `isna()`.

3
Higienizar a base preenchendo nulos válidos e eliminando duplicidades operacionais.

4
Executar agrupamentos com `groupby()` e exportar indicadores sumarizados para Excel.



Visualização com Matplotlib e Seaborn

ANÁLISE GRÁFICA

Visualizando Dados

Gráficos traduzem números em diagnósticos:

Histogramas: Distribuição de prazos.

Barras: Custo por família de materiais.

Dispersão: Correlação entrega/avarias.



Ponto-chave

Matplotlib gera a base; Seaborn refina a estética.

Detecção de Outliers e o Boxplot

CONTROLE DE QUALIDADE

Identificando Anomalias


Boxplot resume mediana e quartis (IQR), isolando pontos extremos (**outliers**).

Na gestão, outliers apontam erros de preço, consumo atípico ou desvios de estoque.



Atenção

Investigue outliers: evite compras automáticas baseadas em demandas anômalas.



Automação de Relatórios Descritivos

O Fluxo Manual Repetitivo

- Abrir arquivos pesados diariamente.
- Copiar dados de várias planilhas.
- Corrigir erros e aplicar filtros manuais.
- Alto risco de erro e fadiga da equipe.



Atenção

Processo lento: consome 4h diárias.

A Solução Automatizada em Python

- Script agendado lê dados automaticamente.
- Limpeza e resumo estatístico instantâneos.
- Exporta planilhas e gráficos padronizados.
- Foco total na análise estratégica.



Ponto-chave

Rotina completa em cinco segundos.

Ganhos de Performance: Python vs Planilhas

EFICIÊNCIA CORPORATIVA

Escala e Limites

Planilhas limitam-se a 1M de linhas e travam com fórmulas complexas. Python/Pandas processa milhões de registros na RAM via instruções otimizadas. Consolidações que levam 20min no Excel ocorrem em milissegundos no Python.



Curiosidade

Amazon e Mercado Livre usam pipelines Python para recalcular rotas e estoques continuamente.



Verificação: Performance de Dados

Por que o ecossistema Python com Pandas supera as planilhas convencionais em operações logísticas complexas?

1.

Porque o Excel não possui nenhuma fórmula estatística de agregação ou média.

2.

Porque o Pandas só funciona se a base tiver menos de cem mil registros de movimentação.

3.

Porque processa dados em memória contígua vetorizada, suportando milhões de linhas com automação total.

4.

Porque o Python não precisa de memória RAM para executar cálculos em arquivos de texto.

Verificação: Performance de Dados



Por que o ecossistema Python com Pandas supera as planilhas convencionais em operações logísticas complexas?

1.

Porque o Excel não possui nenhuma fórmula estatística de agregação ou média.

2.

Porque o Pandas só funciona se a base tiver menos de cem mil registros de movimentação.

3.


Porque processa dados em memória contígua vetorizada, suportando milhões de linhas com automação total.

4.

Porque o Python não precisa de memória RAM para executar cálculos em arquivos de texto.

Projeto Prático: O Desafio dos 50 Mil SKUs

Cenário: Assistente de controle de materiais em e-commerce. Recebeu 50.000 movimentações com erros e valores zerados. Desenvolva o script de tratamento para gerar indicadores de giro e nível de serviço ao comitê de compras.



Projeto Prático: Script de Auditoria

Desenvolver um pseudocódigo ou script estruturado em Python para auditar uma base de materiais:

1. Importe a biblioteca Pandas e carregue o arquivo 'inventario_bruto.csv'.


1. Execute a contagem de registros nulos da coluna 'quantidade_fisica'. Substitua nulos por zero.

1. Elimine movimentações duplicadas mantendo a última ocorrência registrada.

1. Calcule o custo médio imobilizado por tipo de produto através de `groupby('categoria')['custo'].mean()`.

1. Salve o resultado sumarizado no arquivo 'relatorio_final_diretoria.xls'.

1. Grave os comandos



Decisão Gerencial: Automação vs Intervenção



Um script em Python apontou que 12% dos registros de lead time de um fornecedor estratégico estavam corrompidos e preencheu todos automaticamente com a mediana histórica. Como gestor de materiais, você aceita o relatório final sem questionamentos ou exige uma auditoria manual detalhada das notas fiscais originais? Quais riscos operacionais a automação cega pode acarretar para a linha de produção?

Decisão Gerencial: Automação vs Intervenção



Você poderia ter dito...

Aceitar estatísticas sem contexto mascara atrasos e desabastece a fábrica.

A mediana suaviza variações, escondendo crises ou gargalos.

Use abordagem híbrida: automação alerta falhas para análise humana.

Síntese e Próxima Fronteira

AVANÇO DA TRILHA

O Que Aprendemos e o Próximo Passo

Dominou Pandas, trocou planilhas por scripts e automatizou análises estatísticas.

No **Bloco 06 (Visualização)**, conectaremos dados a **Power BI/Tableau** para criar dashboards executivos interativos.



Lembre-se

A qualidade dos gráficos e decisões depende da limpeza de dados feita hoje.

